Universidad del Rosario | Educación Continua

Módulo 2

DIPLOMADO EN CIENCIA DE DATOS

Universidad del Rosario | Educación Continua

Introducción a R y análisis estadístico

En este módulo:

Un primer contacto con R

Análisis estadístico de datos

Más sobre R

Universidad del Rosario | Educación Continua

Un primer contacto con R

- R es un software libre y de código abierto (free and open-source) para análisis estadísticos

- Creado por Ross Ihaka y Robert Gentleman de la Universidad de Auckland (Nueva Zelanda), basado en el lenguaje S

- Actualmente es manejado por R-Project for Statistical Computing: http://www.r-project.org/

- Es compatible con Mac, Windows y Linux

Un primer contacto con R

- Tiene un amplio número de recursos y actualizaciones en tiempo real
  - CRAN dispone de mas de 3500 librerías
  - http://rseek.org/
  - The R Journal https://journal.r-project.org/

- "Poderoso" y amigable para la realización de gráficas y mapas

- Compatible con otro tipo de lenguajes (traductores disponibles) para Matlab, S, SAS, Julia, …

Universidad del Rosario | Educación Continua

Consola de R

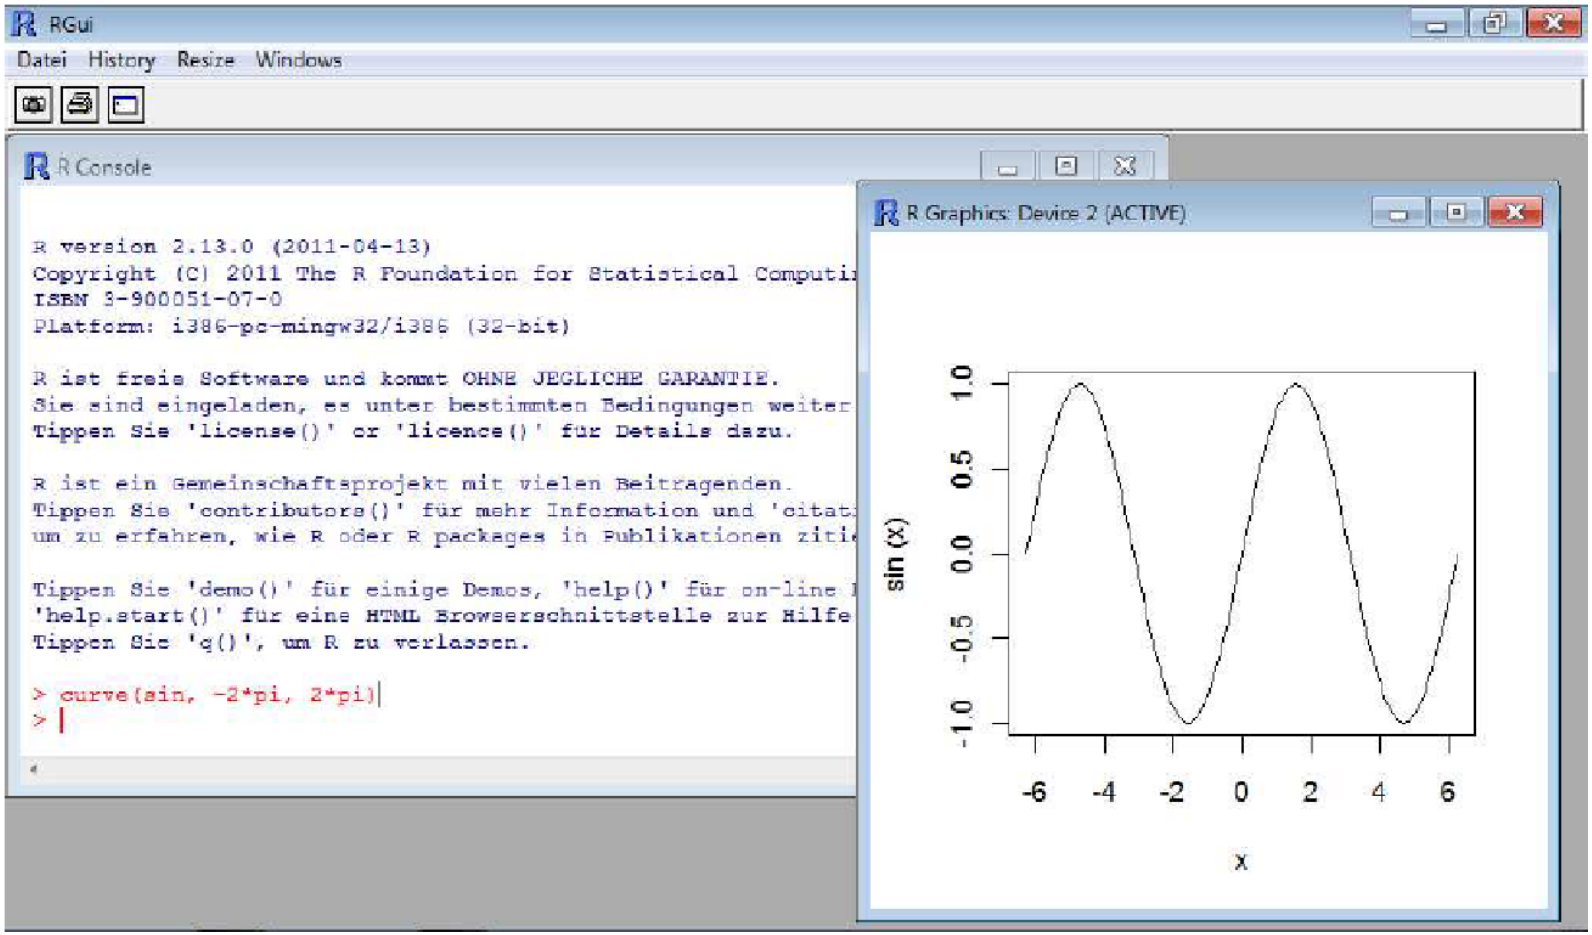


```
> curve(sin, -2*pi, 2*pi)
```

Universidad del Rosario | Educación Continua

Rstudio IDE

- RStudio IDE es una plataforma de programación (integrated development environment) para R
- RStudio hace más amigable la interacción con R
- Se encuentra disponible en http://www.rstudio.com/
- Es compatible con Mac, Windows y Linux

Universidad del Rosario | Educación Continua

Consola Rstudio

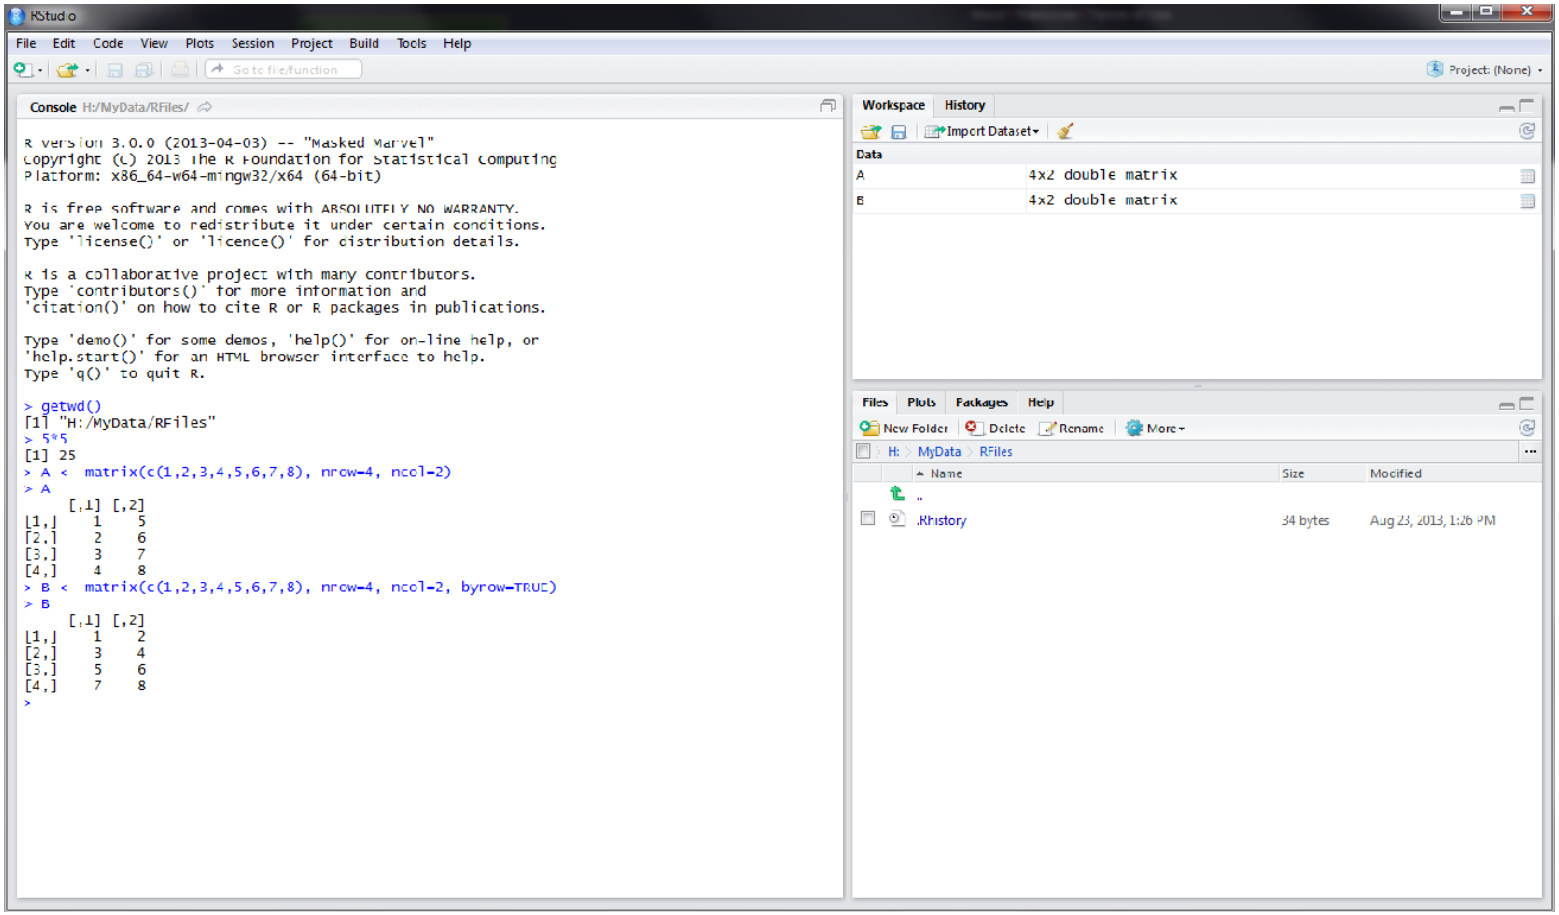

Universidad del Rosario | Educación Continua

Consola Rstudio

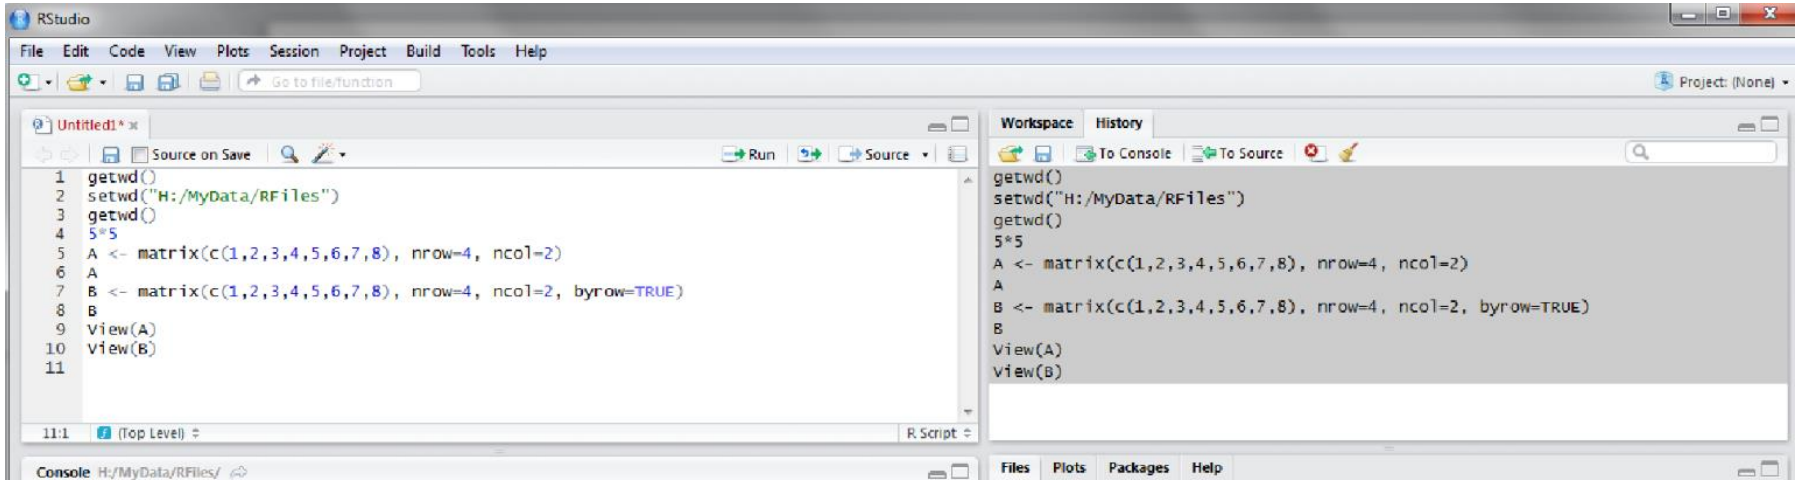

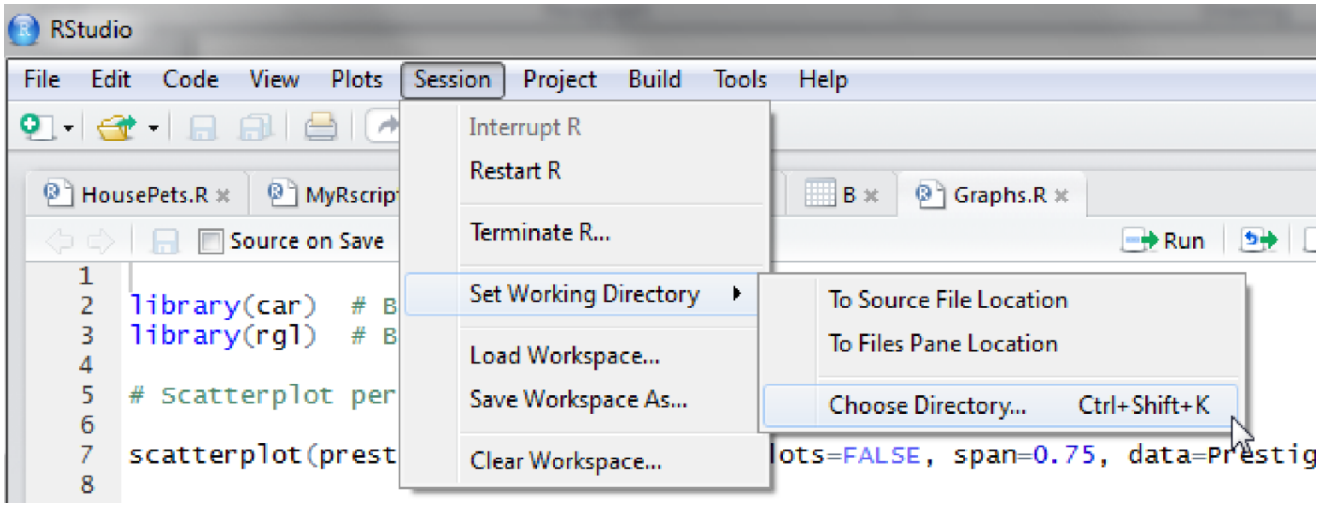

Universidad del Rosario | Educación Continua

Consola Rstudio

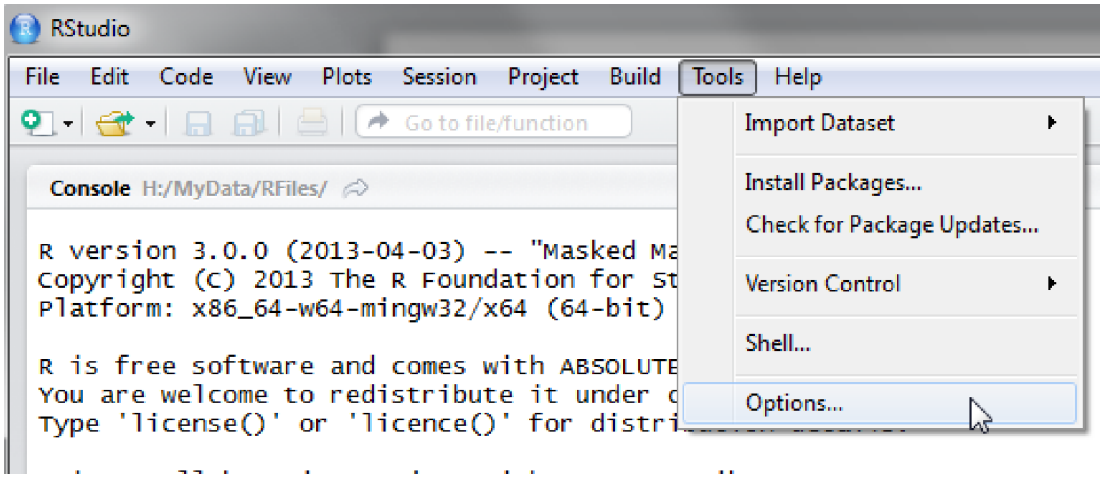

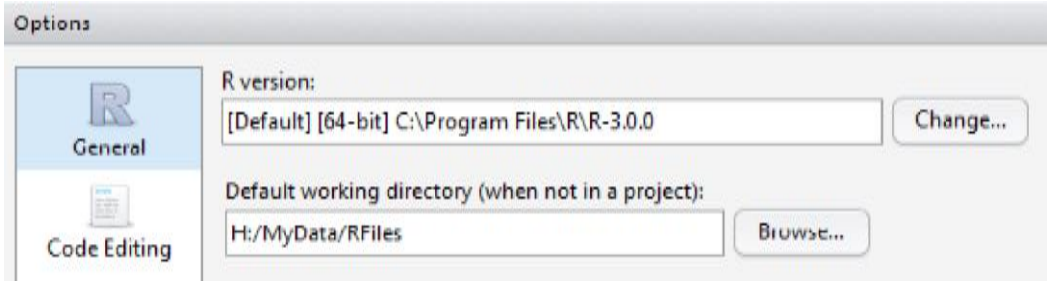

Consola Rstudio

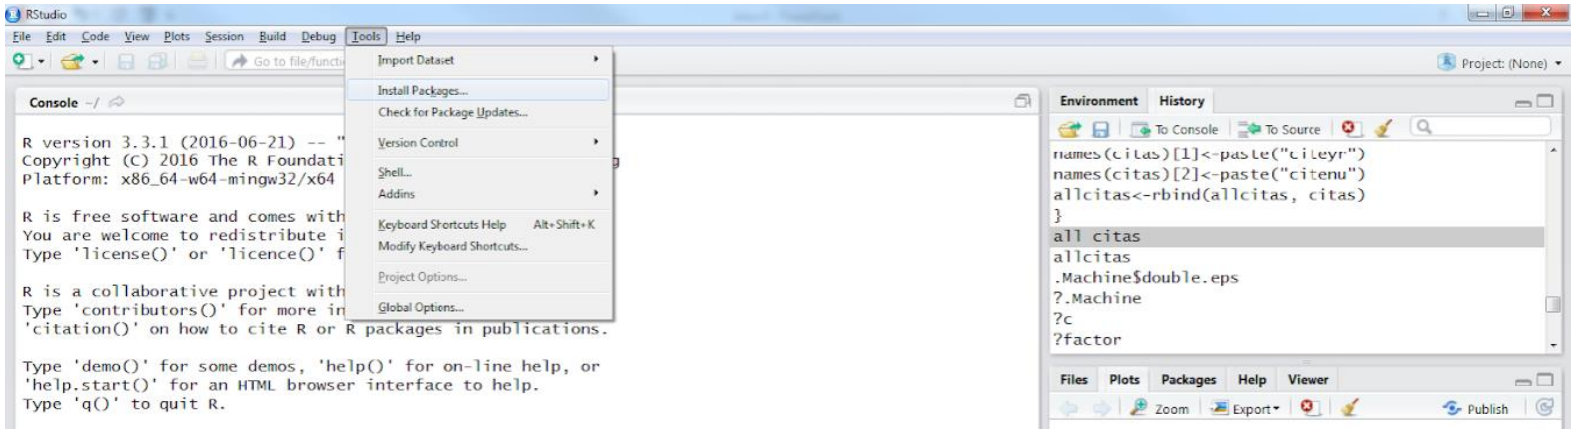

Instalemos el paquete rgl, es útil para gráficas en 3D

Conociendo el ambiente R

Nota: Para correr en Rstudio, se utiliza la combinación de teclas Ctr+Enter. Desde la consola basta con Enter

- Demos

```
> demo()
> demo(graphics)
> demo(persp)
> demo(image)
```

Universidad del Rosario | Educación Continua

Conociendo el ambiente R

- Instalación de paquetes

```
> install.packages("pkg1")
> install.packages(c("pkg1", "pkg2"))
```

- Cerrar R

```
> q()
```

- Definir un objeto

```
> objeto<-…
> x<-2
```

Universidad del Rosario | Educación Continua

Conociendo el ambiente R

- Ver objetos

```
> ls()
```

- Ver contenido directorio actual

```
> dir()
```

- Ver dirección actual de directorio

```
> getwd()
```

- Cambiar dirección actual de directorio

```
> setwd("/home/user")
```

Universidad del Rosario | Educación Continua

Conociendo el ambiente R

- Sintaxis general

```
> objeto<-función(argumentos)
```

- Ayuda

```
> ?función
> help(función)
```

- Cargar Librería

```
> library("nombre")
```

- Lista de funciones en una librería

```
> library(help="nombre")
```

Universidad del Rosario | Educación Continua

Conociendo el ambiente R

- Ejecutar Script auxiliar

```
> source("Script.R")
```

- Borrar un objeto

```
> rm("objeto")
```

- Borrar todos los objetos en "Environment"

```
> rm(list=ls())
```

- Hacer comentarios…

```
> # Hola!!!!
```

Cálculos básicos

- Suma y resta

```
> 3+2
> 3-2
```

- Multiplicatión y división

```
> 3*2
> 3/2
```

Universidad del Rosario | Educación Continua

Cálculos básicos

- Exponentes

```
> 3^2
> 3^(1/2)
```

- Constantes importantes

```
> pi
> exp(1)
```

Nota: Las funciones pueden escribirse en una única línea de comando

```
> 2+3; 3-2; 5*2; 15/3; 2^5; sin(1)
```

Universidad del Rosario | Educación Continua

Valores especiales en R

- Infinito

```
> Inf
> 1+Inf
```

- Nivel de precisión (Machine epsilon)

```
> .Machine$double.eps
> ?.Machine
> 0>.Machine$double.eps
```

Manipulación de variables

- Definir valores particulares dos variables, e.g., `x`, `y`:

```
> x<-3  (x=3)
> y<-2  (y=2)
```

- Cálculos a partir de `x`, `y`

```
> x+y
> x*y
```

Nota: R es case-sensitive, es decir distingue entre `x` y `X`.

Nota: R sobre-escribe cuando se asigna un nuevo valor a un objeto ya creado.

Funciones en R

R es un lenguaje que emplea funciones (como otros software, e.g., Stata, Eviews, Python, etc.), donde cada función esta identificada (nombrada) de manera única

Una función básica permite combinar elementos (números, caracteres, cadenas de texto -strings-) en un único objeto o **lista** (elementos del mismo tipo)

```
> c(1,3,-2)
> c("a","a","b","b","a")
```

Universidad del Rosario | Educación Continua

Funciones básicas

- Suma y media

```
> sum(c(1,3,-2))
> mean(c(1,3,-2))
```

- Varianza y desviación estandar

```
> var(c(1,3,-2))
> sd(c(1,3,-2))
```

- Minimo y máximo

```
> min(c(1,3,-2))
> max(c(1,3,-2))
```

Nota: Lo anterior se puede simplificar definiendo un objeto, e.g., `x<-c(1,3,-2)`.

Universidad del Rosario | Educación Continua

Funciones básicas

- Definir objetos

```
> x<-c(1,3,4,6,8)
> y<-c(2,3,5,7,9)
```

- Correlación y covarianza

```
> cor(x,y)
> cov(x,y)
```

- Combinación de columnas y filas

```
> cbind(x,y)
> rbind(x,y)
```

Otras funciones importantes

- Sucesiones de números

```
> c(1:4); 3*c(1:4)
> seq(-5,5,by=0.2)
> seq(length=51, from=-5, by=0.2)
```

- Raíz cuadrada

```
> sqrt(c(1:4))
```

- Mediana y ordenamiento

```
> x<-c(8.97, 10.06, 9.29, 7.44, 9.48)
> median(x)
> sort(x)
```

- Producto de vectores elemento a elemento

```
> c(1:4)*c(4:1)
```

Programación orientada a objetos

R está basado en la manipulación de objetos que están asociados a una clase (“class”) que indica el tipo de objeto que representa

Las funciones de R están definidas para una clase particular de objetos

Por ejemplo, no se pueden sumar ni restar cadenas de texto

Universidad del Rosario | Educación Continua

Clases de objetos

- Numéricos

```
> x<-c(1,3,4,6,8)
> x
> class(x)
```

- Enteros

```
> x<-c(1L,3L)
> x
> class(x)
```

- Caracteres

```
> x<-c("a","a","b")
> x
> class(x)
```

Clases de objetos

- Factores o categorías

```
> x<-factor(c("a","a","b"))
> ?factor
> x
> class(x)
```

- Matrix

```
> x<-c(1,3,-2)
> y<-c(2,1,6)
> z<-cbind(x,y)
> z
> class(z)
```

Clases de objetos

- Base de datos (Data frame)

```
> x<-c(1,3,-2)
> y<-c(”a”, ”a”, ”b”)
> z<-data.frame(x,y)
> z
> class(z)
```

Transformación de objetos

- Numérico vs carácter

```
> x<-c(1,3,-2)
> is.numeric(x)
> as.character(x)

> y<-c("1","3","-2"); y
> is.character(y)
> as.numeric(y)
```

Nota: Estas transformaciones también pueden aplicarse a grandes volúmenes de datos.

Transformación de objetos

```
> x<-c(1,”a”,-2)
> class(x)
# en este caso los datos se conforman como carácter
```

Operadores lógicos

- Los operadores lógicos son aquellos que arrojan como resultado “verdadero” o “falso”

- Son un tipo de objeto útil para determinar qué funciones o líneas de comando se deben ejecutar de acuerdo con la satisfacción de una condición

Principales operadores lógicos

Operador	Función
<	Menor que
>	Mayor que
<=	Menor o igual que
>=	Mayor o igual que
==	Igual a
!=	Diferente a
!x	“no” x
x | y	x o y
x & y	x y y

Universidad del Rosario | Educación Continua

Uso de operadores lógicos

Ejemplo 1:

```
> x<-y<-5
> x<y
> x<=y
> x>y
> x==y
> x!=y
```

Ejemplo 2:

```
> x<-5 ; y<-10
> (x<10 | y<10)
> (x<10 & y<10)
```

Tipo lógico

```
> x <- 1:10 < 5 ; x
# Conjunto de valores lógicos
> class(x)
> is.character(x)
> is.numeric(x)
> as.numeric(x)
```

Universidad del Rosario | Educación Continua

Tipo lógico

```
> !x
# Negación de x
> which(x)
# Muestra los índices (posiciones) en los que x toma el valor “True”
```

Tipo lógico

- Algunas operaciones de matrices

```
> y <- c(TRUE, TRUE, FALSE, FALSE)
> as.numeric(y)
> y & TRUE
> y & FALSE
> !y
> y | FALSE
```

Funciones adaptables a objetos

Existen funciones que varían sus resultados dependiendo del tipo de objeto al que se aplica

- Imprimir o mostrar

```
> x <- c(1,3,-2)
> y <- c(”a”, ”a”, ”b”)
> print(x)
> print(y)
> print(paste(”el primer elemento de x es”, x[1]))
```

Nota: `paste` es una función muy útil para la presentación de resultados y el estudio basado en textos.

Funciones adaptables a objetos

- Resumen

```
> x<-c(1,3,-2)
> y<-factor(c("a", "a", "b"))
> summary(x)
> summary(y)
```

- Rango

```
> range(x)
> range(y)
```

```
# R informa de manera explícita errores al aplicar funciones que no se adaptan a una clase particular de objeto
```

Universidad del Rosario | Educación Continua

Vectores y matrices

- Vectores

```
> x <- 1:10; names(x) <- letters[1:10]; x
> x[1:5]
> x[c(2,3,5)]
> x[c(”b”, ”d”)]
# Invoca elementos particulares

> y <- rep(0,3)
# Repetir valores en un vector
> x<-array(1:60, c(5,4,3))
# Arreglo matricial
```

Vectores y matrices

- Matrices

```
> x <- matrix(1:30, 3, 10)
> class(x)
> x[1:2,]
> x[,1:2]
> dim(x)
> nrow(x); ncol(x)
> as.vector(x)
# Vectorización
```

Nota: Una matrix puede contruirse con cualquier tipo de objetos, pero todos los elementos deben ser del mismo tipo

Vectores y matrices

- Algunas operaciones de matrices

```
> x <- matrix(1:30, 3, 10)
> x+1; x*2; x/3; exp(x)
# Operaciones elemento a elemento
> y <- 1:3
> x*y
# Multiplicación elemento a elemento
> z <- 1:10
> x%*%z
# Multiplicación matricial
```

Universidad del Rosario | Educación Continua

Vectores y matrices

- Algunas operaciones de matrices

```
> x <- matrix(1:30, 3, 10)
> is.matrix(x)
> t(x)
# Transposición de matrices

> diag(x)
# Diagonal de x
> diag(diag(x))

> solve(x)
# Matriz diagonal
> x%*%solve(x)
```

Vectores y matrices

- Algunas operaciones de matrices

```
> y <- matrix(runif(9), 3, 3)
> solve(y)
> y %*% solve(y)

> solve(y, rep(1,3))
> y %*% solve(y, rep(1,3))
```

Vectores y matrices

- Algunas operaciones de matrices

```
> det(x)
# Determinante de la matriz

> x <- matrix(c(13, -4, 2, -4, 11, -2, 2, -2, 8), 3, 3,
byrow=TRUE)
> eigen(x)
> ev <- eigen(x)
> vectors <- ev$vectors
# Valores propios y vectores propios
```

Ver en qué consiste "value" dentro de una función: e.g., ?eigen

```
> x <- matrix(rexp(100, rate=.1), ncol=10)
# Matrices de números aleatorios siguiendo distribución exponencial
> x <- matrix(runif(100), ncol=10)
```

Universidad del Rosario | Educación Continua

Concatenando objetos

- Concatenación de listas

```
> x<-1:3
> y<-101:103
> c(x,y)
```

- Combinación por columnas y filas

```
> z<-cbind(x,y)
> w<-rbind(z,z)
```

Universidad del Rosario | Educación Continua

Listas

Las listas contienen objetos de diferente tipo que pueden ser referenciados como `$"nombre"` o `[["numero"]]`. Dichas listas también pueden anidarse

```
> x<-list(One=11:15, Two=c("a", "b",
    "c"), Three=(1:4)); x
> y<-list(x=x, Four=1:3); y

> x$One; y$x$One
> y$Four; y[[2]]
```

Universidad del Rosario | Educación Continua

Datos disponibles en R

https://stat.ethz.ch/R-manual/R-devel/library/datasets/html/00Index.html

```
> data(austres)
> ?austres
> View(austres)
> summary(austres)
> austres[1]
> austres[1:5]
```

Otras bases de datos disponibles:
https://vincentarelbundock.github.io/Rdatasets/datasets.html

Universidad del Rosario | Educación Continua

Datos disponibles en R

```
> data(mtcars)
> ?mtcars
> View(mtcars)
> summary(mtcars)
> names(mtcars)
# Ver nombre de las columnas
> mtcars$mpg[1:10]
# Invocar una columna particular
> mtcars[mtcars$am==1]
# Cuál es el error?
> mtcars[mtcars$am==1,]
> mtcars[mtcars$am==1,2:5]
> length(mtcars)
```

Universidad del Rosario | Educación Continua

Datos disponibles en R

```
> x<-mtcars[mtcars$am==1,]
# Crear sub dataset
> x
> x$hcyl<-x$cyl>4
# Crear nueva variable
> x$hcyl<-as.numeric(x$hcyl)
> x$hmpg<-as.numeric(x$mpg>mean(x$mpg))
> x$hmpg<-NULL
# Borra una variable de la base de datos
```

Universidad del Rosario | Educación Continua

Funciones sobre Datasets

- Dimensión

```
> length(mtcars)
> length(mtcars$hp)
> dim(mtcars)
> rownames(mtcars)
> colnames(mtcars)
```

- Índices (posiciones) y ordenamiento

```
> sort(mtcars$hp)
# Ordena los valores de la variable indicada
> order(mtcars$hp)
# Encuentra los índices o posiciones del vector
    ordenado
```

Universidad del Rosario | Educación Continua

Funciones sobre Datasets

- Indices (posiciones) y ordenamiento

```
> mtcars2 <- mtcars[order(mtcars$mpg),]
# Crea una nueva base de datos ordenado por mpg

> mtcars2 <- mtcars[order(-mtcars$mpg),]
# Crea una nueva base de datos ordenada,
decreciente, por mpg
```

Funciones sobre Datasets

- Aplicar función a múltiples columnas

```
> mtcars[1:3,1:4] # como obtenemos la media de cada columna o fila?

> mean(mtcars$mpg)
> apply(mtcars[1:3,1:4],1, mean)
> apply(mtcars[1:3,1:4],2, mean)
```

Nota: `apply` permite aplicar una importante serie de funciones de manera recursiva

```
> apply(mtcars[1:3,1:4],2, summary)
> apply(mtcars[1:3,1:4],1:2, function(x) sum(x)/2)
```

Universidad del Rosario | Educación Continua

Funciones sobre Datasets

- Generación de estadísticas agregadas

```
> aggregate(mtcars[,1:4], by=list(mtcars$cyl), FUN=mean)
> aggregate(mtcars[,1:4], by=list(mtcars$cyl), FUN=summary)
```

- Muestreo aleatorio de un dataset

```
> mtcars[sample(1:length(mtcars[,1]),30),]
# submuestra de tamaño 30 sin reemplazamiento

> mtcars[sample(1:length(mtcars[,1]),30, replace=TRUE),]
# submuestra de tamaño 30 con reemplazamiento
```

Ejercicio

Escribir un Script que permita realizar las siguientes operaciones:

- Generar un vector columna de tamaño 50 que distribuya normal con media 10 y varianza 5.
- Generar un vector columna de tamaño 20 con números consecutivos desde -5 con saltos de 1.5
- Combinar los 2 vectores anteriores en un vector columna
- Generar un vector columna que siga una distribución uniforme y pueda combinarse como una columna adicional del objeto anterior
- Del objeto combinado de 2 columnas, extraer la parte que corresponden a valores entre 0,2 – 0,4 y 0,6 -0,8 de la columna 2
- Imprimir una frase que presente la media y desviación estándar de la primera columna

Ejercicio

```
> x<-rnorm(50, 10, sqrt(5))
> y<-seq(length=20, from=-5, by=1.5)

> z<-c(x,y)
  # La función rbind es adaptable a objetos:
> class(x); class(y)
> rbind(x,y)
> rbind(as.matrix(x),as.matrix(y))

> w<-cbind(z, runif(70))

> w<-w[((w[,2]>0.2 & w[,2]<0.4) | (w[,2]>0.6 & w[,2]<0.8)),]
> print(paste("La media de la columna 1 es",         mean(w[,1]),
"y la deaviación estandar es",         sd(w[,1])))
```

Universidad del Rosario | Educación Continua

Histogramas

```
> hist(mtcars$mpg)
```

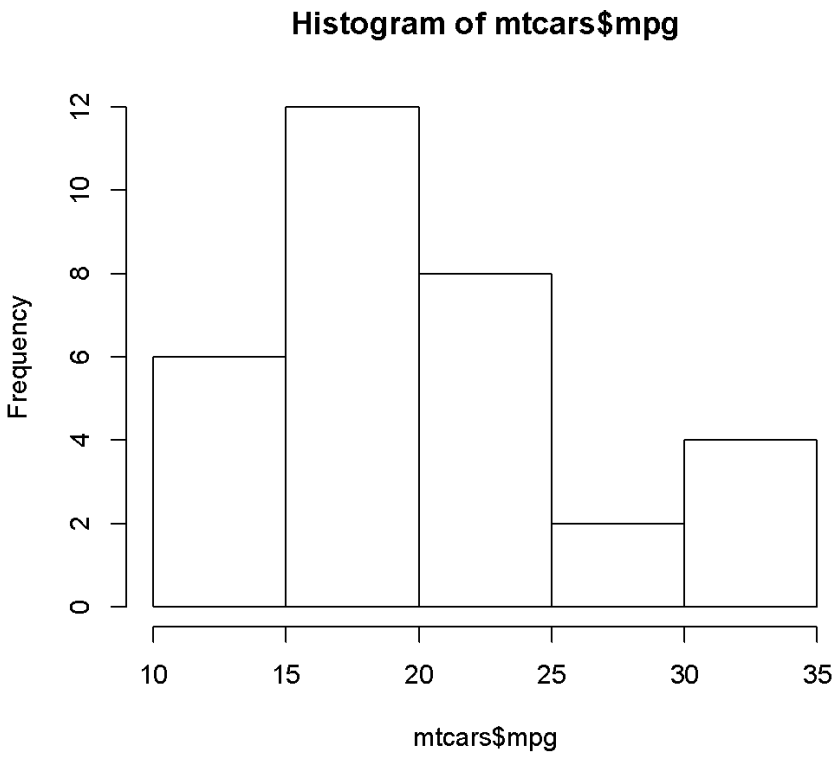

Importar y exportar datos

- Descargar datos de https://www.kaggle.com/deepakg/usarrests
- Importar

```
> setwd("nombre de directorio")
> midata<-
read.csv(file="USArrests.csv")
```

Nota: En ocasiones es necesario indicar que los datos contienen los nombres de las columnas

```
> midata<-read.csv(file="USArrests.csv",
header = TRUE)
```

Importar y exportar datos

Nota: Existen funciones para otros tipos de formatos:

xls

Librería: gdata
Función: read.xls

workbook

Librería: XLConnect
Función: readworksheet

Minitab

Librería: foreing
Función: read.mtp

Importar y exportar datos

- Exportar

```
> sub_midata<-midata[midata$Murder>10,]
> write.csv(sub_midata, file =
"nuevos_datos.csv")
```

Nota: Existe funciones similares para exportar a formatos txt, xls, mtp, …

If/else

Universidad del Rosario | Educación Continua

- Sintaxis general

```
if(…) {
“operaciones”
} else {
“operaciones”
}
```

- Sintaxis anidada

```
if(…) {
“operaciones”
} else if(…) {
“operaciones”
} else {
“operaciones”
}
```

Universidad del Rosario | Educación Continua

If/else

Ejemplo 1:

```
>x<-10
>if(x>5) {
 x<-x/2
 y<-2*x
} else {
 x<-2*2
 y<-x
}
>x
>y
```

Ejemplo 2:

```
>x<-4
>if(x>5) {
 x<-x/2
 y<-2*x
} else {
 x<-2*2
 y<-x
}
>x
>y
```

Loops

- Sintaxis general

```
for(i in I) {
"operaciones"
}
```

- Ejemplo 1

```
> for(i in letters[1:5]) {
      print(i)
      }
```

- Ejemplo 2

```
>x<-11:15
>x
> for(i in 1:5) {
  x[i]=x[i]+1
  }
```

While

- Sintaxis general

```
while(…) {
"operaciones"
}
```

Nota: Las operaciones se llevan a cabo hasta que la condición en (…) no se satisface.

While

Ejemplo 1:

```
>x<-80
>iter<-0
>while(x<100) {
 x<-x+sqrt(x)/10
 iter=iter+1
}
>x
>iter
```

Ejemplo 2:

```
>x<-80
>iter<-0
>while(x<100 & iter<20) {
   x<-x+sqrt(x)/10
   iter=iter+1
}
>x
>iter
```

Ejercicio

Crear un loop en que

- Se calculen 10 matrices de números aleatorios de 3 por 3
- Computar el determinante de la matriz y guardarlo en una matriz o vector
- Calcular estadísticas descriptivas de dicho vector

Ejercicio

Crear un loop en que

- Se calculen 10 matrices de números aleatorios de 3 por 3
- Computar el determinante de la matriz y guardarlo en una matriz o vector
- Calcular estadísticas descriptivas de dicho vector

```
> v<-10
> dets<-matrix(NA, v, 1)

> for (i in 1:v){
  x<-matrix(runif(9), 3)
  dets[i]<-det(x)
}

> summary(dets)
```

Ejercicio

Crear un while que imprima el numero de interaciones que tienen que ocurrir hasta encontrar que la media de un vector de tamaño 100 que distribuye uniforme tenga media menor a 0,6

Ejercicio

Crear un while que imprima el numero de interaciones que tienen que ocurrir hasta encontrar que la media de un vector de tamaño 100 que distribuye uniforme tenga media menor a 0,6

```
> x<-runif(100)
> iter<-0

> while(mean(x)<0.6) {
  iter=iter+1
  print(iter)
  x<-runif(100)
}
```

Universidad del Rosario | Educación Continua

Funciones

- Sintaxis general

```
>nombre<-function(parametros)
{
        "operaciones"
}
```

- Ejemplo

```
> myfun<-function(x) {
 if(x>5) {
         x<-x/2
         y<-2*x
        } else {
         x<-2*2
         y<-x
        }
 return(list(x=x,y=y))
 }
> class(myfun)
> myfun(10)
> myfun(4)
```

Universidad del Rosario | Educación Continua

Otro ejemplo de funciones

```
>myfun2<- function(x, a=0, b=1){
      return(a + b*x)
 }
 # a y b tiene como valores de defecto 0 y 1
respectivamente
> myfun2(0)
> myfun2(5)
> myfun2(5, a=1, b=2 )
> myfun2(5, 1, 2)
> myfun2(c(1:10), a=1, b=2 )
```

Ejercicio

Crear una función que muestre el resultado de elevar `x` a la potencia `y`, e imprima la frase: "`x` elevado a la `y` es igual a ?"

Universidad del Rosario | Educación Continua

Ejercicio

Crear una función que calcule el resultado de elevar `x` a la potencia `y`, e imprima la frase: "`x` elevado a la `y` es igual a ?"

```
> pow<-function(x, y) {
    result<-x^y
    print(paste(x, "elevado a la potencia", y, "es
       igual a",  result))
       }
> pow(2,3)
```

Ejercicio

Crear una función que realice dos procedimiento diferentes con una base de datos, e.g, tabla de descriptivas o gráfica, dependiendo del valor que tome un parámetro

Universidad del Rosario | Educación Continua

Ejercicio

Crear una función que realice dos procedimiento diferentes con una base de datos, e.g, tabla de descriptivas o gráfica, dependiendo del valor que tome un parámetro

```
> mi_des<-function(grafica=1) {
  data(mtcars)
  if (grafica==1) {
    x <- mtcars$mpg
    h<-hist(x,  breaks=10,  col="red",  xlab="Miles  Per
       Gallon",
            main="Histogram with Normal Curve")
    paste("Nota: Como el parametro gráfica es igual a",
          grafica, "se muestra el histograma de mpg")
  } else {
   …
```

Ejercicio

Crear una función que realice dos procedimiento diferentes con una base de datos, e.g, tabla de descriptivas o gráfica, dependiendo del valor que tome un parámetro

```
} else {
    y<-summary(mtcars$mpg)
    print(y)
    paste("Nota: Como el parametro gráfica es igual a",
          grafica, "se muestra las descriptivas de mpg")
  }
}
```

```
> mi_des()
> mi_des(1)
> mi_des(0)
```