

Discriminante lineal

- * Método de clasificación supervisado.
 - * Dos o más grupos son conocidos a priori
 - * $P(Y=k | X = x)$
-
- ✓ Alternativa a la regresión logística cuando hay 2 o más niveles.
 - ✓ Clases bien separadas \rightarrow Parámetros + estables
 - ✓ Equivalente a logística cuando hay solo 2 niveles (tiene el mismo desempeño).

Método:

- 1) Dividir los datos en entrenamiento en el que se conoce a qué grupo pertenece cada observación.
- 2) Probabilidades a Priori (proporción "esperada" en cada grupo).
- 3) Determinar si la varianza o matriz de covarianzas es homogénea (Prueba de homogeneidad de varianzas entre las clases).
De ello depende LDA o QDA.
- 4) Estimar los parámetros necesarios para las funciones de probabilidad condicional.
(verificando las condiciones)
- 5) Calcular el resultado de la clasificación

6) --> Verificar el resultado de la función discriminante. (Indica dónde se asigna la observación)

7) Usar validación cruzada para estimar las probabilidades de clasificaciones erróneas.

Teorema de Bayes para Clasificación.

2 Eventos \rightarrow A
 \searrow
B

$$P(B|A) = \frac{P(A \cap B)}{P(B)}$$

* Probabilidad a priori $P(Y=k) = \pi_k$
 $k=1, \dots, C$ C: # clases

* $f_k(x) = P(X=x | Y=k)$

↓
función de densidad
condicional de x para
una observación que
pertenece a la clase K .

- * $f_k(x)$ grande \rightarrow Mayor probabilidad
de que la observación
pertenezca a K .

- * Probabilidad a posteriori:

$$P(Y=k | X=x)$$

La probabilidad de que una observación
pertenezca a K siendo x el valor predictor.

$$P(Y=k | X=x) = \frac{\pi_k P(X=x | Y=k)}{\sum_{i=1}^K \pi_i P(X=x | Y=i)}$$

$$= \frac{\pi_k \cdot f_k(x)}{\sum_{i=1}^k \pi_i \cdot f_i(x)}$$

La clasificación con menor error se consigue asignando la observación que maximice la probabilidad a posteriori.

Como $\sum_{i=1}^k \pi_i \cdot f_i(x)$ es igual para todas las clases

$$P(Y=k | X=x) \propto \pi_k \cdot f_k(x).$$

Se selecciona el mayor $\pi_k f_k(x)$


Estimailos

$$\hat{\pi}_k = \frac{n_k}{N}$$

H_0 : las observaciones se distribuyen

de forma normal.

$$f_k(x) = P(Y=k \mid X=x)$$
$$= \frac{1}{\sqrt{2\pi}\sigma_k} \cdot e^{-\frac{1}{2\sigma_k^2}(x-\mu_k)^2}$$

1) Asumiendo σ_k cte.

$$P(Y=k \mid X=x) = \frac{\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}(x-\mu_k)^2}}{\sum_{j=1}^K \pi_j \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}(x_i-\mu_j)^2}} \cdot \pi_k.$$

$$\hat{S}_k = \log(P(Y=k \mid X=x))$$

$$= -\frac{1}{2\sigma^2} (x^2 - 2x\mu_k + \mu_k^2) + \ln(\pi_k)$$
$$- \ln(\text{cte})$$

$$d \frac{x_{ik}}{\sigma^2} - \frac{y_k^2}{2\sigma^2} + h(\pi_k).$$

Estimadores:

$$\hat{M}_k = \frac{1}{n_k} \sum_{i \in Y_k} x_i \quad \leftarrow \text{Promedio}$$

$$\hat{\sigma}_k = \frac{1}{N-k} \sum_{i=1}^k \sum_{i \in Y_k}^{n_k} (x_i - \hat{M}_k)^2$$

\leftarrow Suma ponderada de varianzas.

$$\hat{\pi}_k = \frac{n_k}{n} \quad \leftarrow \text{Proporción.}$$

Ejemplo 2 Clases.

$$P(Y=k | X=k)$$

↳ x se asigna a la clase 1
con probabilidad

$$P(Y=1 | X=x)$$

y a la clase 2 con probabilidad

$$P(Y=2 | X=x)$$

$$\frac{P(Y=1 | X=x)}{P(Y=2 | X=x)} > 1$$

Límite de desición:

$$x = \frac{M_1 + M_2}{2}$$

$$\frac{xM_2 - \frac{M_2^2}{2\sigma^2} + h(\pi_2)}{\sigma^2} > 1.$$

$$\frac{\chi \mu_2}{\sigma^2} - \frac{\mu_2^2}{2\sigma^2} + \ln(\pi_2)$$

$$\frac{2\chi\mu_1 - \mu_1^2 + 2\sigma^2 \ln(\pi_1)}{2\chi\mu_2 - \mu_2^2 + 2\sigma^2 \ln(\pi_2)} > 1.$$

$$2\chi\mu_1 - \mu_1^2 + 2\sigma^2 \ln(\pi_1) > 2\chi\mu_2 - \mu_2^2 + 2\sigma^2 \ln(\pi_2)$$

$$2\chi(\mu_1 - \mu_2) - (\mu_1^2 - \mu_2^2) + 2\sigma^2(\ln(\pi_1) - \ln(\pi_2)) > 0$$

$$\chi > \frac{(\mu_1^2 - \mu_2^2) - 2\sigma^2(\ln(\pi_1) - \ln(\pi_2))}{2(\mu_1 - \mu_2)}$$

$$\chi > \frac{(\mu_1^2 - \mu_2^2) - 2\sigma^2(\ln(\pi_1/\pi_2))}{2(\mu_1 - \mu_2)}$$

$$\chi > \frac{(\cancel{\mu_1 - \mu_2})(\mu_1 + \mu_2) - 2\sigma^2(\ln(\pi_1/\pi_2))}{2(\cancel{\mu_1 - \mu_2})}$$

$$z > \frac{(H_1 + H_2)}{2} - \frac{\sigma^2 \ln(\pi_1/\pi_2)}{(H_1 - H_2)}.$$

Si $\pi_1 = \pi_2$ entonces.

$$x > \frac{H_1 + H_2}{2}$$

El algoritmo de clasificación LDA.

1) Apostar $\hat{g}_k(x)$ para $k=1, 2, \dots, c$.

$$\hat{g}_k(x) = x \frac{\hat{H}_k}{\hat{\sigma}^2} - \frac{\hat{H}_k^2}{2\hat{\sigma}^2} + \log(\hat{\pi}_k)$$

2) Buscar el valor de k donde $\hat{g}_k(x)$ sea máximo

Se denomina análisis discriminante lineal pq $\hat{\delta}_k(x)$ es lineal para el valor de x .

$$\hat{\delta}_k(x) = ax + b$$

$$a = \frac{\hat{\mu}_k}{\hat{\sigma}^2} \quad b = \frac{\hat{\mu}_k^2}{2\hat{\sigma}^2} + \log(\hat{\pi}_k).$$

CASO MULTIVARIADO

$$X \sim N(\mu, \Sigma)$$

$$E(X) = \mu \quad \text{Cov}(x) = \Sigma$$

$$f(x) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp\left\{-\frac{1}{2} (x-\mu)' \Sigma^{-1} (x-\mu)\right\}$$

$$P(Y=k | X=x)$$

$$= \frac{\frac{1}{(2\pi)^{pk/2} |\Sigma|^{1/2}} e^{\left\{-\frac{1}{2}(x-\mu_k)' \Sigma^{-1} (x-\mu_k)\right\}}}{\sum_{i=1}^c \pi_i \frac{1}{(2\pi)^{pk/2} |\Sigma|^{1/2}} e^{\left\{-\frac{1}{2}(x-\mu_i)' \Sigma^{-1} (x-\mu_i)\right\}}}.$$

$$\ln(P(Y=k | X=x)) =$$

$$\begin{aligned} & \frac{1}{2} \ln(|\Sigma|) - \frac{1}{2}(x-\mu_k)' \Sigma^{-1} (x-\mu_k) + \ln(\pi_k) \\ & - \ln(\text{cte}) \end{aligned}$$

$$\frac{1}{2} \ln(|\Sigma|) - \frac{1}{2} x' \Sigma^{-1} x + \frac{1}{2} \mu_k' \Sigma^{-1} \mu_k$$

$$\underbrace{\left(\frac{1}{2} \mu_k' \Sigma^{-1} x\right)'}_{\text{Un əm 5 əs}} + \underbrace{\frac{1}{2} x' \Sigma^{-1} \mu_k}_{11 \cdot \pi \cdot 1} - \ln(\text{cte})$$

$$J^* = -\frac{1}{2} \ln(\|\Sigma\|) - \ln(\text{cte})$$

Simétrica.

$$= \frac{1}{2} \ln(\|\Sigma\|) - \frac{1}{2} x' \Sigma^{-1} x + \boldsymbol{\mu}_k' \Sigma^{-1} x - \frac{1}{2} \boldsymbol{\mu}_k' \Sigma^{-1} \boldsymbol{\mu}_k$$

$$+ \ln(\pi_k) - \ln(\text{cte})$$

$$f_k(x) = \boldsymbol{\mu}_k' \Sigma^{-1} x - \frac{1}{2} \boldsymbol{\mu}_k' \Sigma^{-1} \boldsymbol{\mu}_k + \ln(\pi_k).$$

Versión vectorial

Nota:

- El desarrollo anterior supone que Σ es cte para todas las clases, bajo suposición de homogeneidad de varianzas.

Límite de desición.

$$\boldsymbol{\mu}_k' \Sigma^{-1} x - \frac{1}{2} \boldsymbol{\mu}_k' \Sigma^{-1} \boldsymbol{\mu}_k + \ln(\pi_k) >$$

$$\boldsymbol{\mu}_l' \Sigma^{-1} x - \frac{1}{2} \boldsymbol{\mu}_l' \Sigma^{-1} \boldsymbol{\mu}_l + \ln(\pi_l)$$

Para los valores de α tales que se cumpla la condición la clasificación se hace para el grupo K en vez del grupo d .

Se calcula \hat{S}_k para todos los valores de K .

Clasificación:

$$\hat{S}_k(x) = x' \hat{\Sigma}^{-1} \hat{\mu}_k - \frac{1}{2} \hat{\mu}_k' \hat{\Sigma}^{-1} \hat{\mu}_k + \log \hat{\pi}_k$$

$\hat{\Sigma}$ ← Matriz de varianzas y covarianzas

$\hat{\mu}_k$ ← Vector de medias

$\hat{\pi}_k$ ← Probabilidades a priori

Seleccionar como clase el valor más grande

de δ_k

Análisis discriminante (cuadrático)

1. Se asume que $\Sigma_1 \neq \Sigma_p$

para algún par de grupos

2. Cada $X \sim N(\mu_k, \Sigma_k)$

3.

$$\delta_k(x) = -\frac{1}{2}(x - \mu_k)^T \cdot \Sigma_k^{-1} (x - \mu_k) - \frac{1}{2} \log |\Sigma_k| + \log \pi_k.$$

$$= -\frac{1}{2} x^T \Sigma_k^{-1} x + x^T \Sigma_k^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma_k^{-1} \mu_k - \frac{1}{2} \log |\Sigma_k| + \log \pi_k.$$

Aparece este término.

$$P(Y=k | X=x)$$

$$\begin{aligned}
 &= \frac{\frac{1}{(2\pi)^{\frac{p}{2}} |\Sigma_k|^{1/2}} e^{\left\{-\frac{1}{2}(x-\mu_k)^\top \Sigma_k^{-1} (x-\mu_k)\right\}}}{\sum_{i=1}^c \pi_i \frac{1}{(2\pi)^{\frac{p}{2}} |\Sigma_i|^{1/2}} e^{\left\{-\frac{1}{2}(x-\mu_i)^\top \Sigma_i^{-1} (x-\mu_i)\right\}}} \cdot \pi_k \\
 &\quad \text{↑ mano mano}
 \end{aligned}$$

$$\begin{aligned}
 &= -\frac{1}{2} \ln(|\Sigma_k|) - \frac{1}{2} (x - \mu_k)^\top \Sigma_k^{-1} (x - \mu_k) \\
 &\quad + \ln(\pi_k) - \ln(\text{cte})
 \end{aligned}$$

$$\begin{aligned}
 &\propto -\frac{1}{2} \ln(|\Sigma_k|) - \frac{1}{2} x^\top \Sigma_k^{-1} x + \frac{1}{2} x^\top \Sigma_k^{-1} \mu_k \\
 &\quad + \frac{1}{2} \mu_k^\top \Sigma_k^{-1} x - \frac{1}{2} \mu_k^\top \Sigma_k^{-1} \mu_k - \ln(\pi_k)
 \end{aligned}$$

$$\propto -\frac{1}{2} \ln(|\Sigma_k|) - \frac{1}{2} x^\top \Sigma_k^{-1} x + x^\top \Sigma_k^{-1} \mu_k$$

$$-\frac{1}{2} \mathbf{y}_k^T \Sigma_k^{-1} \mathbf{y}_k + \ln(\pi_k) = \delta_k$$

1. Término cuadrático.

2. Depende del valor de $|\Sigma_k|$

3. Requiere estimar

$\frac{p(p+1)}{2}$ parámetros para Σ_k

$p \rightarrow \# \text{ variables.}$ $\sum_{i=1}^n i = \frac{n(n+1)}{2}$

[ $\frac{n(n+1)}{2}$ valores diferentes]

Ejemplo W.A. - Generando Números Aleatorios.

$$U_1 \sim U(0,1) \quad U_2 \sim U(0,1)$$

$$\theta = 2\pi U_1 \quad S = -\ln(U_2)$$

$$X = R \cos \theta \quad R = \sqrt{2S^1}$$

$$Y = R \sin \theta$$

$$X = \sqrt{2(-\ln(U_2))} \cdot \cos(2\pi(U_1))$$

$$X_1 = [0.18; 0.78; -0.73; -1.32; \\ 1.07; 0.81; -1.1418; -2.03; \\ 1.40; -2.01; -2.082; 3.66; \\ 2.42; 3.45; 3.52; 3.74; 3.89; \\ 4.11; 3.29; 2.51; 2.96; 0.31; \\ -0.11; 0.29; -0.01; 0.59; -0.22; \\ 0.99]$$


Discriminante lineal. - Ejemplo # 1.

1. Generar normales multivariadas (con la misma varianza).

$$\hat{S}_k(x) = x' \hat{\Sigma}^{-1} \hat{\mu}_k - \frac{1}{2} \hat{\mu}_k' \hat{\Sigma}^{-1} \hat{\mu}_k + \log \hat{\pi}_k$$

1. Simular una normal multivariada con $p=2$. Con un vector de medias específico y una matriz de varianzas común. (con 3 clases)

20 observaciones x cada clase.



LDA y Regresión logística.

Simular los escenarios.


Escenario 1.

$$n=20 \quad k=2.$$

Cada clase tiene distribución normal de forma no correlacionada.

$$X_1 \sim N(\mu_1, \sigma)$$

$$X_2 \sim N(\mu_2, \sigma)$$



1) Generar 2 normales
incorreladas con
medias diferentes.

2) Clasificar por
KNN, NNN-cv.
LDA, logística y
QDA.

3) Repetir y calcular los errores

4) Comparar.

LOOCV. \rightarrow CV

loss function
trap

C
volc
Bos